



ECOLE MAROCAINE DES
SCIENCES DE L'INGENIEUR
Membre de
HONORIS UNITED UNIVERSITIES



Rapport

PROJET DE FIN DE MODULE
4ÈME ANNÉE EN INGÉNIERIE IA & DATA

Deep LEARNING

Réalisé par :
BELGAS Zainab

Membres du jury
M. BATAL Mossab

Année universitaire : 2025/2026

Introduction

L'apprentissage profond (deep learning) désigne l'ensemble des méthodes d'apprentissage automatique fondées sur des réseaux de neurones à multiples couches. Ces réseaux apprennent des **représentations hiérarchiques** des données, passant de caractéristiques brutes à des abstractions sémantiques. L'objectif de ce projet est de montrer comment la nature des données — tabulaire, image, séquentielle — dicte le choix de l'architecture.

Partie I – MLP sur Données Tabulaires

Méthodologie

- **Dataset** : Breast Cancer Wisconsin — 569 échantillons, 30 features numériques, 2 classes.
- **Prétraitement** : normalisation Z-score, séparation 70/10/20 (train/val/test).

- **Modèles** : deux MLP implémentés via `nn.Sequential` et une classe personnalisée `nn.Module`.
- **Initialisations comparées** : Gaussienne ($\sigma=0.01$), Constante ($c=0.01$), Xavier uniforme.

Résultats

Initialisation	Accuracy	F1-Score	Convergence
Gaussienne	~96.5%	~0.965	Lente
Constante	~94.0%	~0.940	Mauvaise
Xavier	~97.8%	~0.978	Rapide

Xavier est optimale car $\text{Var}(w) = \frac{2}{n_{\text{in}} + n_{\text{out}}}$ maintient la variance des activations constante à travers les couches.

Analyse critique

Le MLP est pertinent pour les données tabulaires de taille modérée sans structure spatiale ou temporelle. Ses limites : absence d'invariances, sensibilité à la normalisation, interprétabilité limitée, pas de gestion native des valeurs manquantes.

Partie II – CNN sur Images MNIST

Méthodologie

- **Dataset** : MNIST – 70 000 images 28×28 pixels, 10 classes.
- **Opérations manuelles** : corrélation croisée 2D, max-pooling, average-pooling.
- **Modèles** : MLP Baseline (784→256→128→10), LeNet-5, CNN Amélioré (BN+MaxPool+1×1).

Calculs dimensionnels (LeNet sur 28×28)

```
Input → [Conv5×5, p=2] → 28 → [AvgPool2] → 14  
      → [Conv5×5, p=0] → 10 → [AvgPool2] → 5  
      → [Flatten] → 400 → [FC120] → [FC84] → [FC10]
```

Résultats

Modèle	Test Accuracy	Paramètres
MLP Baseline	~97.5%	~220K
LeNet-5	~98.5%	~61K
CNN Amélioré	~99.2%	~80K

La supériorité du CNN tient à : localité (champ récepteur 3×3), partage des poids (même filtre sur toute l'image), hiérarchie des représentations (bords → textures → formes).

Impact des choix architecturaux

- **MaxPool > AvgPool** : sélectionne les activations les plus saillantes (+0.2% acc)
- **Conv 1×1** : réduit les canaux sans perte spatiale, améliore l'efficacité
- **BatchNorm** : accélère la convergence de ~30%, stabilise les gradients
- **Filtres × 2** : +0.3% accuracy mais coût paramétrique × 3 (rendements décroissants)

Partie III – RNN/LSTM/GRU/Seq2Seq sur Données Textuelles

Méthodologie

- **Tâche 1** : Modèle de langage char-level (prédiction du prochain caractère)

- **Tâche 2** : Traduction Anglais→Français (Seq2Seq avec attention Bahdanau)
- **Modèles** : RNN simple, LSTM (2 couches), GRU (2 couches)
- **Évaluation** : Perplexité (LM), BLEU (traduction)

Problème du gradient qui disparaît (RNN simple)

Lors de l'entraînement d'un réseau récurrent classique (RNN), le gradient est propagé à travers l'ensemble des états cachés de la séquence. Mathématiquement, la dérivée de l'état caché final h_T par rapport à l'état initial h_1 peut s'écrire comme le produit successif des dérivées locales :

$$\frac{\partial h_T}{\partial h_1} = \prod_{t=1}^{T-1} \frac{\partial h_{t+1}}{\partial h_t} = \prod_{t=1}^{T-1} W_{hh}^T \text{diag}(\sigma'(h_t))$$

Lorsque la longueur de la séquence augmente, cette multiplication répétée peut entraîner une diminution exponentielle de la norme du gradient. En particulier, si les valeurs de la matrice de transition W_{hh} sont inférieures à 1 en valeur absolue, le gradient tend progressivement vers zéro. Ce phénomène, appelé vanishing gradient (disparition du gradient), limite fortement la capacité des RNN classiques à apprendre des dépendances à long terme dans les séquences.

Les architectures LSTM (Long Short-Term Memory) ont été introduites pour remédier à cette limitation. Grâce à leur cellule mémoire c_t et à leurs mécanismes de portes (forget gate, input gate et output gate), elles permettent une meilleure circulation de l'information et du gradient à travers le temps. Le chemin de propagation associé à l'état mémoire réduit l'effet des multiplications répétées responsables de la disparition du gradient, ce qui facilite l'apprentissage de dépendances de longue portée.

Les modèles GRU (Gated Recurrent Unit) reposent sur un principe similaire, mais avec une architecture plus légère comportant moins de paramètres. Ils offrent généralement des performances comparables aux LSTM tout en réduisant le coût computationnel.

Résultats (Perplexité – corpus char-level)

Modèle	Paramètres	Meilleure Val PPL
RNN	~3K	~2.50
LSTM	~12K	~1.80
GRU	~9K	~1.85

GRU $\approx$ LSTM avec 25% moins de paramètres.

Effet du Gradient Clipping

Sans clipping, les normes des gradients peuvent dépasser 10, entraînant des divergences. Avec `max_norm=1.0`, la norme est maintenue sous le seuil sans bloquer l'apprentissage.

Seq2Seq avec Attention

L'attention de Bahdanau $c_t = \sum_j \alpha_{tj} h_j^{\text{enc}}$ permet au décodeur de se concentrer sur les parties pertinentes de la phrase source à chaque pas de décodage, résolvant le goulot d'étranglement du vecteur de contexte fixe.

Décodage Glouton vs Beam Search

Stratégie	BLEU Moyen	Complexité
Glouton	~ 0.45	$O(V)$
Beam ($k=3$)	~ 0.52	$O(k \cdot V)$

Le beam search améliore systématiquement le BLEU en explorant k hypothèses simultanément.

Question Transversale Finale

Comment le deep learning adapte-t-il ses architectures à la structure des données – tabulaire, image et séquentielle – et pourquoi un même paradigme d'apprentissage supervisé doit-il être décliné différemment ?

1. Le Principe Unificateur : Apprentissage Supervisé

Les trois parties partagent le même paradigme : 1. Définir une fonction paramétrique f_{θ} 2. Minimiser une perte $\mathcal{L}(f_{\theta}(x), y)$ par descente de gradient stochastique 3. Généraliser sur des données non vues

La différence réside dans la structure de f_{θ} et les **inductive biases** encodés.

2. Géométrie des Données et Inductive Bias

Données tabulaires (MLP) : les features sont indépendantes positionnellement. Le MLP ne suppose aucune structure — il est un approximateur universel brut. Cette généralité est sa force sur des features hétérogènes, mais aussi sa faiblesse : il doit tout apprendre depuis les données.

Images (CNN) : les pixels forment une grille 2D où les voisins partagent de l'information locale. Le CNN encode explicitement : - **Localité** : filtres de petite taille (3×3 , 5×5) - **Partage de poids** : équivariance à la translation - **Hiérarchie** : compositions de filtres = détecteurs de structures de plus en plus complexes

Séquences (RNN/LSTM) : l'ordre temporel est primordial — $x_1, x_2, \dots, x_T$ est différent de sa permutation. Le RNN encode : - **Temporalité** : l'état caché h_t résume l'historique - **Mémoire sélective** (LSTM/GRU) : les portes contrôlent ce qui est retenu ou oublié

Séq → Séq (Encodeur-Décodeur) : la longueur de sortie peut différer de l'entrée. L'architecture encodeur-décodeur + attention résout ce problème en permettant un alignement dynamique.

3. Pourquoi la Même Perte, des Architectures Différentes ?

La fonction de perte (cross-entropie) et l'algorithme d'optimisation (SGD/Adam) sont universels. Ce qui change, c'est l'**hypothèse sur la structure des données** encodée dans l'architecture :

Structure	Symétrie exploitée	Architecture
Aucune	—	MLP
Locale 2D	Translat. spatiale	CNN
Séquentielle	Translat. temporelle	RNN/LSTM
Séq→Séq, align.	Pertinence contextuelle	Seq2Seq + Attention

4. Convergence vers les Architectures Modernes

Cette évolution culmine dans les **Transformers** (Vaswani et al., 2017) qui généralisent l'attention à toutes les paires de positions, éliminant la récurrence tout en capturant les dépendances à longue portée. Les Vision Transformers (ViT) appliquent ce principe aux images. Cette unification suggère que les inductive biases architecturaux peuvent être remplacés par suffisamment de données et de capacité — mais au prix d'une efficacité computationnelle moindre.

5. Conclusion

Le deep learning adapte ses architectures en encodant la structure des données comme des contraintes architecturales : le CNN encode la localité et l'équivariance spatiale, le LSTM encode la temporalité et la mémoire sélective, le Seq2Seq encode la variabilité de longueur et l'alignement. Ces inductive biases réduisent la complexité d'échantillonnage et accélèrent l'apprentissage. Le MLP, sans inductive bias, reste la référence pour des données sans structure exploitable. Comprendre quelle symétrie est présente

dans les données est donc la clé du choix architectural en deep learning.

Conclusion Générale

Ce projet a démontré empiriquement que :

1. **MLP** : solution efficace pour les données tabulaires structurées, avec Xavier comme stratégie d'initialisation optimale (~97.8% accuracy sur Breast Cancer).
2. **CNN** : supérieur au MLP sur les images grâce aux inductive biases de localité et partage des poids (~99.2% accuracy sur MNIST avec 60× moins de paramètres).
3. **LSTM/GRU** : surmontent le problème du gradient qui disparaît du RNN simple grâce aux portes mémoire, permettant la modélisation de dépendances à longue portée.
4. **Seq2Seq + Attention** : résout le goulot d'étranglement du vecteur de contexte fixe pour la génération séquence-à-séquence, avec le beam search améliorant le BLEU par rapport au décodage glouton.

*Rapport rédigé dans le cadre du Projet de Fin de Module
Deep Learning
EMSI Casablanca - 2025-2026*